

Reconstrução de Superfícies 3D a Partir de Nuvens de Pontos: Uma Análise Comparativa

1st João Pedro Felício Prudencio

Centro de Ciências Tecnológicas

UDESC - Universidade do Estado de Santa Catarina

Joinville, Brasil

joao.prudencio@edu.udesc.br

2nd Leandro Ribeiro Rittes

Centro de Ciências Tecnológicas

UDESC - Universidade do Estado de Santa Catarina

Joinville, Brasil

leandro.rittes1990@edu.udesc.br

Abstract—Este artigo compara sistematicamente os principais métodos de reconstrução de superfícies 3D a partir de nuvens de pontos. Analisamos quatro categorias: triangulação, abordagens volumétricas, funções implícitas e deep learning. Para cada uma, detalhamos propostas, funcionamento, resultados e limitações de estudos relevantes. Uma comparação geral final sintetiza o desempenho desses métodos. Concluimos que a escolha ideal depende do contexto, com a integração de técnicas tradicionais e modernas de deep learning mostrando-se promissora para o desafio da reconstrução 3D de dados brutos e ruidosos.

Index Terms—Reconstrução 3D, Nuvens de Pontos, Triangulação, Métodos Volumétricos, Função Implícita, Deep Learning

I. INTRODUÇÃO

A reconstrução de geometrias 3D é uma área de pesquisa fundamental com crescentes aplicações em diversos campos, como engenharia reversa, realidade virtual e aumentada, medicina, robótica, arqueologia e preservação cultural [1]. A base para muitas dessas aplicações reside na capacidade de digitalizar objetos e ambientes do mundo real, transformando-os em representações computacionais que podem ser processadas, analisadas e manipuladas. Esse processo frequentemente se inicia com o escaneamento 3D, uma técnica que, impulsionada pela crescente disponibilidade de dispositivos de escaneamento 3D acessíveis e poderosos, permite a captura de dados espaciais de uma superfície ou objeto [1].

A. Nuvens de Ponto

O escaneamento 3D geralmente produz como resultado inicial uma nuvem de pontos, conforme mostra a Figura 1: um conjunto de coordenadas (x, y, z) que representam amostras da superfície de um objeto, mas sem conexão topológica entre os pontos [1]. Apesar de ser uma forma direta de representar geometria, essa estrutura é limitada para aplicações que exigem superfícies contínuas, como simulações, renderizações ou fabricação.

Para tais aplicações, é comum converter nuvens de pontos em representações geométricas mais estruturadas, como malhas triangulares, superfícies paramétricas ou volumes voxelizados. Essa conversão, conhecida como reconstrução de superfície, é necessária porque nuvens de pontos reais costumam apresentar ruído, ausência de dados e distribuição irregular. O objetivo é transformar essa informação bruta em

uma superfície contínua e coerente, apropriada para uso em engenharia, visualização ou manufatura [2].



Fig. 1. Exemplo de nuvem de pontos [2]

B. Histórico e avanços na área

A reconstrução 3D evoluiu de métodos baseados em modelos geométricos explícitos e priors definidos manualmente [2], para abordagens mais robustas que lidam melhor com a complexidade das nuvens de pontos reais. Com o surgimento do aprendizado profundo, tornou-se possível aprender essas informações diretamente dos dados, ampliando a capacidade dos sistemas em lidar com ruídos, lacunas e variabilidade geométrica [2]. Este artigo examina as principais abordagens de reconstrução 3D, destacando tanto os métodos tradicionais quanto os avanços proporcionados pelo deep learning.

II. FUNDAMENTAÇÃO TEÓRICA

A reconstrução de superfícies a partir de nuvens de pontos busca gerar representações contínuas e coerentes a partir de dados discretos e desordenados. Ao longo do tempo, surgiram diversos métodos com abordagens distintas, incluindo triangulação, técnicas volumétricas, funções implícitas e, mais recentemente, aprendizado profundo [1], [2].

A. Conceitos gerais

Os métodos se dividem entre os que interpolam os pontos da nuvem e os que apenas os aproximam. Além disso, distinguem-se entre representações explícitas (como malhas) e implícitas (como funções escalares no espaço 3D) [1]. A escolha da representação impacta diretamente a robustez do método frente a ruídos, topologias complexas e amostragens irregulares – desafios comuns em nuvens de pontos reais [2].

B. Métodos Baseados em Triangulação

Métodos de triangulação constroem superfícies explícitas conectando diretamente os pontos da nuvem, formando malhas compostas por triângulos, como mostra a Figura 2 [1]. Um dos principais algoritmos é a Triangulação de Delaunay, que em 3D divide o espaço em tetraedros e extrai a superfície a partir das fronteiras desses elementos. Outra abordagem é o Ball-Pivoting Algorithm (BPA), que simula uma esfera rolando sobre a nuvem. Quando a esfera toca três pontos, ela forma um triângulo, e continua a rolar pelas arestas formadas, adaptando-se à densidade dos dados [1]. Esses métodos são eficazes para capturar conectividade local, mas podem ser sensíveis a ruído e distribuição irregular dos pontos.




Fig. 2. Exemplo método de triangulação

C. Métodos Volumétricos

Os métodos volumétricos transformam o espaço ao redor da nuvem de pontos em uma grade de voxels e classificam cada célula conforme sua relação com a superfície desejada [1]. Voxels são unidades cúbicas que representam volumes em uma grade tridimensional, semelhantes aos pixels em imagens 2D, mas no espaço 3D. Cada voxel armazena informações sobre uma pequena porção do espaço, como cor, densidade ou distância à superfície, como ilustrado na Figura 3. A superfície é então obtida como a fronteira entre regiões "internas" e "externas". O algoritmo Marching Cubes é amplamente utilizado nesse contexto: ele opera sobre campos escalares (como o Signed Distance Function), avaliando os valores nos vértices de cada cubo para determinar onde a superfície cruza o espaço. Usando uma tabela de casos pré-definidos, gera triângulos que aproximam a geometria local [1]. Esses métodos são robustos a ruídos e eficazes para preencher lacunas, graças à natureza contínua da representação.

D. Métodos de Função Implícita

Esses métodos buscam definir uma função $f(x,y,z)=0$ cuja superfície de nível zero representa a forma 3D desejada, como é possível ver na Figura 4. Utilizando a nuvem de pontos para inferir essa função, garante-se que os pontos estejam na superfície ou próximos dela, possibilitando modelar topologias complexas e evitando buracos na superfície [2]. Um exemplo popular é o Poisson Surface Reconstruction, que interpreta as normais dos pontos como um campo vetorial e resolve um problema de Poisson para reconstruir uma função indicadora do volume, extraindo a superfície com Marching




Fig. 3. Exemplo método volumétrico [7]

Cubes [2]. Outra técnica comum usa Superfícies de Nível Radial (RBFs) para interpolar a função implícita a partir dos pontos e normais.




Fig. 4. Exemplo de função implícita

E. Métodos Baseados em Deep Learning

Com o avanço do deep learning, surgiram métodos que aprendem diretamente representações e priors de grandes bases de dados, diferenciando-se dos métodos tradicionais baseados em heurísticas [2]. Redes neurais são treinadas para mapear nuvens de pontos para superfícies 3D (ver Figura 5), com diferentes estratégias: geração direta de malhas, aprendizado de funções implícitas (como campos de distância assinada - SDF), reconstrução por voxels e processamento direto de nuvens de pontos via arquiteturas como PointNet e PointNet++ [2]. Esses métodos oferecem maior robustez a ruídos e dados incompletos, além de melhor generalização para novas formas.




Fig. 5. Exemplo de método de aprendizagem profunda

III. METODOLOGIA DE BUSCA

Esta revisão bibliográfica seguiu uma abordagem sistemática para localizar e analisar estudos sobre reconstrução

3D a partir de nuvens de pontos, detalhando as bases de dados utilizadas, as estratégias de busca e os critérios de seleção adotados.

A. Bases de dados utilizadas

Foram consultadas três bases acadêmicas principais:

- IEEE Xplore, por sua relevância em engenharia e ciência da computação, especialmente em reconstrução 3D;
- Google Scholar, como apoio complementar para ampliar os resultados e identificar versões expandidas;
- Web of Science, por seu rigor e cobertura multidisciplinar de publicações de alto impacto.

Essas bases foram escolhidas por sua credibilidade e por fornecerem acesso a trabalhos revisados por pares, assegurando a qualidade das referências.

B. Estratégia de busca

Foram definidas quatro strings específicas, cada uma voltada para um tipo de método de reconstrução 3D:

- ("3D reconstruction" OR "surface reconstruction") AND ("point cloud" OR "3D scanning") AND triangulation AND ("case study" OR application OR evaluation)
- ("3D reconstruction" OR "surface reconstruction") AND ("point cloud" OR "3D scanning") AND volumetric AND ("case study" OR application OR evaluation)
- ("3D reconstruction" OR "surface reconstruction") AND ("point cloud" OR "3D scanning") AND ("implicit function" OR "implicit surface") AND ("case study" OR application OR evaluation)
- ("3D reconstruction" OR "surface reconstruction") AND ("point cloud" OR "3D scanning") AND "deep learning" AND ("case study" OR application OR evaluation)

Essas combinações com operadores booleanos garantiram abrangência e precisão, priorizando artigos com aplicações práticas, validações experimentais ou estudos de caso.

C. Critérios de seleção

Para garantir a relevância dos materiais analisados, os seguintes critérios de inclusão foram aplicados:

- O artigo deveria abordar de forma clara um método de reconstrução 3D a partir de nuvens de pontos ou dados escaneados.
- O método apresentado precisava se enquadrar em uma das quatro categorias abordadas (triangulação, volumétrico, função implícita ou deep learning).
- O artigo deveria apresentar ao menos um estudo de caso, experimento prático ou avaliação empírica dos resultados.

IV. ANÁLISE COMPARATIVA

Nesse contexto, as próximas subseções apresentam e analisam os artigos selecionados para cada método. Inicialmente, são feitas análises individuais de cada artigo, organizadas por abordagem.

A. Triangulação

Três estudos foram analisados nesta seção, todos utilizando triangulação para reconstrução de superfícies 3D a partir de nuvens de pontos, cada um com enfoques e aplicações distintos.

- 1) **Miao et al. (2019)**: Desenvolveram um método voltado à reconstrução de superfícies 3D a partir de imagens multivista, frequentemente ruidosas. Utilizam triangulação de Delaunay para gerar uma malha inicial, seguida pela construção de um grafo duplo que auxilia na definição de vizinhanças. A reconstrução é refinada com corte de grafo para isolar regiões prováveis da superfície e ajustada com base em semelhança fotométrica, recuperando detalhes finos. Testado em conjuntos como Castle e Herzjesu, obteve alta precisão e completude. O principal desafio é o alto custo computacional do processo.
- 2) **Lv et al. (2021)**: Focam na aplicação prática de monitoramento em tempo real da impressão 3D. Usam algoritmos de extração de características (FFT-SIFT e AKAZE) combinados com Structure from Motion (SfM) para gerar nuvens de pontos. A reconstrução se dá por triangulação de Delaunay e mapeamento de textura, resultando em superfícies detalhadas com erro de apenas 0,014%. Apesar da precisão, a abordagem é sensível a variações de iluminação e à uniformidade de cor das peças, funcionando melhor em ambientes controlados.
- 3) **Bernardini et al. (1999)**: Propõem o Ball Pivoting Algorithm (BPA), método baseado em uma esfera que gira entre pontos vizinhos formando triângulos sucessivamente. É eficiente e robusto, sendo capaz de lidar com milhões de pontos, como demonstrado na digitalização da escultura Pietà de Michelangelo. Sua simplicidade é uma vantagem, mas o resultado depende criticamente do tamanho da esfera: valores inadequados podem causar perdas de detalhe ou falhas na malha.

B. Volumétrico

Os três estudos a seguir aplicam estratégias volumétricas distintas: otimização matemática, amostragem estatística e métodos inspirados em segmentação de imagens.

- 1) **Ochmann et al. (2019)**: Propõem reconstruir o interior de edifícios a partir de nuvens de pontos, gerando modelos 3D com volumes conectados (paredes, pisos e cômodos). Superfícies planas são detectadas e agrupadas automaticamente, e a montagem do modelo é feita por programação linear inteira. Os modelos finais são compatíveis com sistemas BIM. Testes em escaneamentos reais mostraram bons resultados, embora o método dependa da segmentação inicial e seja computacionalmente intensivo.
- 2) **Hou et al. (2019)**: Desenvolvem um sistema para reconstrução em ambientes industriais, guiando robôs na escolha do próximo ponto de escaneamento. Usam mapas volumétricos (Octrees) e estimam a incerteza em cada voxel. O Gibbs Sampling é aplicado para escolher

TABLE I
COMPARAÇÃO ENTRE MÉTODOS DE RECONSTRUÇÃO 3D POR TRIANGULAÇÃO

Critério	Miao et al. (2019)	Lv et al. (2021)	Bernardini et al. (1999)
Proposta	Reconstruir superfícies detalhadas com precisão e robustez	Medir peças durante a impressão 3D em tempo real	Criar malhas de forma simples e eficiente a partir de escaneamentos
Contexto de aplicação	Reconstrução multivista (várias fotos de cenas reais)	Ambientes industriais e impressoras 3D	Digitalização 3D de esculturas e objetos físicos reais
Como funciona	Triangulação, corte de grafo e ajuste por imagens	Extração de pontos em imagens + SFM + triangulação de Delaunay	Esfera gira entre pontos para formar triângulos sucessivos
Tecnologias envolvidas	Delaunay, dual graph, corte de grafo, Laplace, similaridade de imagem	FFT-SIFT, AKAZE, Structure from Motion (SFM), Delaunay	Ball Pivoting, conceito próximo de alpha-shapes
Datasets utilizados	Castle, Castle-Entry, Fountain, Herzjesu	Peças reais impressas com impressora 3D (ambiente controlado)	Esculturas digitalizadas (ex: Pietà de Michelangelo)
Métricas de avaliação	Comparação com modelos reais, visualização, precisão geométrica	Erro relativo (0,014%) e tempo de resposta	Avaliação visual e conectividade da malha final
Resultados práticos	Malhas mais completas, detalhadas e resistentes a ruído	Reconstrução precisa e rápida para controle em tempo real	Malhas eficientes com milhões de pontos e robustas a ruído leve
Limitações	Alto custo computacional e ajuste delicado de parâmetros	Funciona melhor em ambientes controlados com objetos simples	Sensível ao tamanho da esfera e à densidade dos pontos

TABLE II
COMPARAÇÃO ENTRE MÉTODOS DE RECONSTRUÇÃO 3D POR MÉTODO VOLUMÉTRICO

Critério	Ochmann et al. (2019)	Hou et al. (2019)	Jeong et al. (2018)
Proposta	Modelo 3D completo de prédios com volumes conectados	Melhorar escaneamento com mapas de ocupação e Gibbs Sampler	Usar campo de fase para formar volumes a partir de nuvens de pontos
Contexto de aplicação	Reconstrução de interiores de edifícios (BIM)	Inspeção industrial e reconstrução com robôs	Reconstrução geral a partir de dados simulados ou escaneados
Como funciona	Detecta planos, segmenta cômodos e resolve equações de otimização	Usa mapas de voxels e escolhe o próximo ponto de vista com base na incerteza	Evolui uma função matemática até formar a superfície desejada
Tecnologias principais	RANSAC, segmentação por visibilidade, programação inteira	Octree, mapas de ocupação, Markov Chain Monte Carlo (Gibbs)	Campo de fase, indicadores de borda, métodos explícitos
Datasets utilizados	Escaneamentos reais de prédios internos	Robôs e sensores industriais, ambientes reais	Modelos geométricos simulados e malhas simples
Métricas de avaliação	Coerência do modelo, conectividade entre cômodos	Grau de incerteza, completude do modelo, entropia	Avaliação visual e estabilidade numérica
Resultados práticos	Modelos conectados e exportáveis para BIM	Reconstrução mais precisa e eficiente, mesmo sem modelo prévio	Superfícies contínuas e estáveis, com menos artefatos
Limitações	Custo computacional e dependência da segmentação inicial	Exige muito cálculo para grandes volumes e mapas	Pouca avaliação quantitativa e limitação com formas complexas

pontos de vista que revelem novas informações. Testes práticos mostraram boa cobertura e precisão, com a limitação do alto custo computacional em voxels densos.

- 3) **Jeong et al. (2018)**: Apresentam uma técnica inspirada em segmentação de imagens médicas, usando um campo de fase que evolui até ajustar-se à nuvem de pontos, formando a superfície do objeto. A solução explícita torna o processo rápido. Os resultados visuais foram coerentes em dados simulados, mas faltam métricas quantitativas, e o método tem dificuldades com formas complexas.

C. Funções Implícitas

Esta seção apresenta três métodos que usam funções implícitas para reconstruir superfícies 3D, tratando problemas

como ruído, buracos e dados escassos.

- 1) **Funk et al. (2013)**: O método divide a nuvem de pontos em pequenas regiões chamadas surfels (pequenos pedaços da superfície). Em cada região, ajusta-se um plano usando l1-regularização, uma técnica que reduz o ruído. Depois, essas partes são unidas com funções base (kernels) para formar uma superfície contínua. Testado em dados reais e simulados, funciona bem, mas pode deixar pequenos buracos entre as regiões e exige alto processamento.
- 2) **Yang et al. (2007)**: Para lidar com ruído e pontos fora do lugar (outliers), o método usa o mean shift, que move os pontos para áreas mais densas, limpando o ruído. Os dados são organizados em blocos menores por uma

TABLE III
COMPARAÇÃO ENTRE MÉTODOS DE RECONSTRUÇÃO 3D POR FUNÇÕES IMPLÍCITAS

Critério	Funk et al. (2013)	Yang et al. (2007)	Beale et al. (2016)
Proposta	Superfície suave a partir de regiões locais com ajuste robusto	Reconstrução de alta qualidade com filtragem e funções radiais	Ajuste de superfícies simples (quadrics) com estatística bayesiana
Contexto de aplicação	Ambientes internos escaneados por sensores ruidosos	Escaneamentos 3D com ruído e outliers (ex: objetos complexos)	Modelagem com poucos pontos e formas geométricas simples
Como funciona	Divide em blocos locais, ajusta planos com l1-regularização, combina com kernel	Aplica mean shift, divide em Octree, usa RBF + Partition of Unity	Usa inferência bayesiana para ajustar superfícies quadráticas
Tecnologias envolvidas	Surfels, regressão esparsa, kernel Gaussiano	Mean shift, RBF, PoU, subdivisão espacial	Probabilidade bayesiana, quadric fitting, regularização com prior
Datasets utilizados	Dados sintéticos (Blender) e câmera estéreo real	Bunny, Dragon (Stanford), escaneamentos com ruído	Formas simuladas e dados reais com poucos pontos
Métricas de avaliação	Avaliação visual, robustez e completude	Avaliação visual, tempo de execução, controle de erro por limiar	Distância de Hausdorff, fidelidade da forma ajustada
Resultados práticos	Boa reconstrução mesmo com ruído e buracos	Alta qualidade visual, com remoção eficaz de ruídos e outliers	Ajuste eficiente com poucos dados, respeitando a forma esperada
Limitações	Pequenos buracos entre blocos e custo computacional	Processo de filtragem é demorado; falta de métricas quantitativas	Limitado a formas simples (esferas, cilindros, parábolas)

TABLE IV
COMPARAÇÃO ENTRE MÉTODOS DE RECONSTRUÇÃO 3D COM DEEP LEARNING

Critério	Sharma et al. (2021)	Li et al. (2019)	Kada (2022)
Proposta	Upsampling de nuvens de pontos com predição de normais	Super-resolução e preenchimento de imagens de profundidade	Reconstrução de telhados simples a partir de nuvem de pontos
Contexto de aplicação	Reconstrução geral de superfícies com dados esparsos	Cenas internas com câmeras RGB-D (ex: robótica, AR)	Modelagem de edifícios a partir de dados aéreos (urbanismo)
Como funciona	Extraí características e gera novos pontos e normais usando redes baseadas em PointNet++	Pipeline em três etapas: super-resolução, extração de normais/bordas e otimização com base na imagem RGB	Segmenta faces do telhado e estima inclinações com ConvPoint e PointNet
Tecnologias envolvidas	PointNet++, MLPs, Chamfer Distance, Euclidean Loss	DlapSRN, FCNs baseadas em VGG-16, perda híbrida com dados RGB e de profundidade	ConvPoint, PointNet, modelagem por semi-espacos (half-space modeling)
Datasets utilizados	Sintéticos e reais para nuvem de pontos (ex: PointNet++)	NYU-v2, ICL-NUIM, SUNCG-RGBD, Middlebury, ToFMark	RoofN3D (118 mil edifícios com anotações de telhado)
Métricas de avaliação	Chamfer Distance, perda por vizinhança, erro de normais	RMSE (mm e pixels), acurácia de pose da câmera	IoU, erro angular (MAE), acurácia da presença das faces
Resultados práticos	Nuvens mais densas e suaves, com normais consistentes	Reconstrução com maior fidelidade geométrica e visual	Alta precisão para telhados com formas simples
Limitações	Suaviza detalhes em bordas afiadas	Dependente da qualidade da imagem RGB auxiliar	Restrito a telhados retangulares com até quatro faces

estrutura chamada Octree. Em cada bloco, ajusta uma função local chamada RBF (Radial Basis Function), que representa a superfície. Essas funções são combinadas suavemente para formar o modelo final. O método gera bons resultados visuais, mas é lento e não tem avaliação numérica detalhada.

- 3) **Beale et al. (2016):** Focado em formas simples como esferas ou cilindros, o método usa uma abordagem bayesiana, que combina informações conhecidas com os dados para estimar a forma mais provável, mesmo com poucos pontos. É eficaz para formas regulares, mas não funciona bem com superfícies complexas.

D. Deep Learning

Esta subseção analisa três métodos que usam redes neurais profundas (deep learning) para reconstrução 3D a partir de nuvens de pontos. Apesar de diferentes aplicações, todos buscam melhorar a qualidade dos dados ou representar objetos com mais precisão.

- 1) **Sharma et al. (2021):** O método usa uma rede baseada no PointNet++, que entende tanto detalhes locais quanto o formato geral da nuvem de pontos. Ele faz upsampling (gera mais pontos) e calcula as normais — vetores que indicam a direção da superfície em cada ponto. Isso ajuda a formar superfícies mais suaves. A avaliação, feita com métricas como Chamfer Distance (mede o quão próximos estão os pontos gerados da superfície

TABLE V
COMPARAÇÃO ENTRE OS QUATRO MÉTODOS DE RECONSTRUÇÃO 3D

Critério	Triangulação	Volumétrico	Funções Implícitas	Deep Learning
Cenário em que se destaca	Escaneamento cultural e fotogrametria (ex: monumentos)	Arquitetura, engenharia e inspeção industrial com robôs	Reconstrução local com ruído e dados incompletos	Upsampling e reconstrução de padrões geométricos
Precisão	Alta com múltiplas visões e refinamento fotométrico	Alta com segmentações bem feitas	Boa para formas simples; depende da função usada	Pode ser muito alta com redes bem treinadas
Velocidade	Média; pode ser lenta com refinamento e múltiplas imagens	Lenta, devido a otimizações volumétricas	Boa em métodos diretos; lenta com pré-processamentos	Alta na inferência; lenta no treinamento
Eficiência Computacional	Média a baixa em métodos refinados	Baixa, especialmente com voxels em grande escala	Variável; alguns métodos são eficientes	Alta na execução; exige GPU para treinar
Topologias complexas	Moderada, depende da densidade da malha	Alta, especialmente em espaços bem estruturados	Limitada a superfícies suaves ou primitivas	Alta com redes adaptadas para formas variadas
Robustez a ruído	Boa com visibilidade e refinamento por deformação	Boa com estratégias probabilísticas como Gibbs	Muito boa com filtragem e regularização	Alta se treinado com ruído nos dados
Preservação de detalhes	Excelente com mapeamento de texturas e ajustes finos	Moderada; depende da resolução dos voxels	Boa em regiões densas; limitada por suavização	Pode perder detalhes em regiões com bordas afiadas
Preenchimento de buracos	Limitado; falha em regiões pouco densas	Excelente; cobre regiões não visíveis	Bom em geral, mas pode deixar falhas entre blocos	Muito bom se houver dados semelhantes no treinamento
Vantagens	Simple, interpretável, boa malha final	Gera modelos volumétricos completos	Superfícies suaves, boa com ruído	Adaptável, escalável, excelente com grandes bases
Limitações	Sensível a parâmetros e pode deixar buracos	Computacionalmente custoso; exige segmentação precisa	Limitado a formas simples; falhas em junções complexas	Precisa de muitos dados e depende da base de treino

original), mostrou bons resultados, embora o método perca detalhes em áreas com bordas muito acentuadas.

- 2) **Li et al. (2019)**: Foca na melhoria de imagens de profundidade, que são como mapas de distância capturados por câmeras RGB-D. A rede aumenta a resolução da profundidade (super-resolução), aproveitando informações da imagem colorida (RGB), como bordas e formas. Isso gera superfícies 3D mais completas e detalhadas. O método apresentou bons resultados, mas depende bastante da qualidade da imagem RGB.
- 3) **Kada (2022)**: Desenvolve uma rede para reconstruir telhados simples a partir de nuvens de pontos capturadas por drones. Usa convoluções contínuas (ConvPoint) para dividir as superfícies do telhado e redes do tipo PointNet para estimar suas inclinações. O modelo final é criado pela interseção de planos (half-space modeling). O método é preciso para estruturas simples, mas não funciona bem com telhados complexos.

V. CONCLUSÃO

Esta revisão comparativa analisou quatro categorias principais de métodos para reconstrução 3D a partir de nuvens de pontos: triangulação, volumétricos, funções implícitas e aprendizado profundo. Cada abordagem apresenta vantagens específicas, dependendo do tipo de dado e aplicação. Os métodos de triangulação, como o Ball Pivoting Algorithm (Bernardini et al., 1999), se destacam pela simplicidade e velocidade, sendo eficazes em dados limpos. Abordagens mais elaboradas, como a de Miao et al. (2019), oferecem alta precisão, mas com maior custo computacional. Já o estudo de Lv et al. (2021) mostra sua aplicabilidade em ambientes

industriais controlados. Nos métodos volumétricos, a ênfase está na estruturação espacial e completude dos modelos, como nos trabalhos de Ochmann et al. (2019) e Hou et al. (2019), embora demandem mais processamento. O método de Jeong et al. (2018) oferece uma alternativa experimental com bons resultados visuais. As funções implícitas mostraram boa resistência ao ruído e à incompletude, com destaque para os estudos de Funk et al. (2013) e Yang et al. (2007). O modelo de Beale et al. (2016) é útil com poucos dados, desde que a forma do objeto seja simples. Já os métodos de deep learning, como os de Sharma et al. (2021) e Li et al. (2019), têm grande potencial em melhorar a qualidade da nuvem de pontos, embora ainda enfrentem desafios com formas complexas, como indicado por Kada (2022). Em resumo, a escolha do método mais adequado depende do contexto, qualidade dos dados e objetivo da reconstrução, sendo muitas vezes benéfico combinar abordagens tradicionais com técnicas modernas de aprendizado profundo.

REFERENCES

- [1] A. Khatamian and H. R. Arabnia, "Survey on 3D surface reconstruction," *Journal of Information Processing Systems*, vol. 12, no. 3, pp. 338–357, Sep. 2016.
- [2] C. Sulzer, A. Guajardo, B. Diehm, and J. Denzler, "A survey and benchmark of automatic surface reconstruction from point clouds," *IEEE Transactions on Visualization and Computer Graphics*, vol. 29, no. 8, pp. 3668–3682, Aug. 2023.
- [3] F. Bernardini, J. Mittleman, H. Rushmeier, C. Silva, and G. Taubin, "The ball-pivoting algorithm for surface reconstruction," *IEEE Transactions on Visualization and Computer Graphics*, vol. 5, no. 4, pp. 349–359, Oct.-Dec. 1999.
- [4] W. Miao, Y. Liu, X. Shi, J. Feng, and K. Xue, "A 3D surface reconstruction method based on Delaunay triangulation," in *Image Analysis*

and Recognition. *ICAR 2019. Lecture Notes in Computer Science*, vol. 11663, pp. 51–60, Springer, Cham, 2019.

- [5] L. Meng, Y. Zhu, S. Zhao, and Y. Wang, “A 3D surface reconstruction method for 3D printing process based on structured light vision,” *Applied Sciences*, vol. 11, no. 17, p. 7961, Aug. 2021.
- [6] J. Yang, Z. Wang, C. Zhu, and Q. Peng, “Implicit surface reconstruction from scattered point data with noise,” *International Conference on Intelligent Computing*, vol. 5227, pp. 744–753, 2008.
- [7] D. Jeong, Y. Li, H. J. Lee, S. M. Lee, J. Yang, S. Park, H. Kim, Y. Choi, and J. Kim, “Efficient 3D volume reconstruction from a point cloud using a phase-field method,” *Mathematical Problems in Engineering*, vol. 2018, Article ID 7090186, 9 pages, 2018.
- [8] L. Hou, X. Chen, K. Lan, R. Rasmussen, and J. Roberts, “Volumetric next best view by 3D occupancy mapping using Markov chain Gibbs sampler for precise manufacturing,” *IEEE Access*, vol. 7, pp. 121950–121960, Aug. 2019.
- [9] S. Ochmann, R. Vock, and R. Klein, “Automatic reconstruction of fully volumetric 3D building models from point clouds,” *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 158, pp. 18–31, Dec. 2019.
- [10] E. Funk, L. S. Dooley, A. Boerner, and D. Griessbach, “Implicit scene modelling from imprecise point clouds,” *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. XL-4/W4, pp. 7–11, Dec. 2013.
- [11] D. Beale, Y. L. Yang, N. Campbell, D. Cosker, and P. Hall, “Fitting quadrics with a Bayesian prior,” *Computational Visual Media*, vol. 2, no. 2, pp. 107–117, Jun. 2016.
- [12] J. Li, W. Gao, and Y. Wu, “High-quality 3D reconstruction with depth super-resolution and completion,” *IEEE Access*, vol. 7, pp. 19371–19381, Jan. 2019.
- [13] R. Sharma, T. Schwandt, C. Kunert, S. Urban, and W. Broll, “Point cloud upsampling and normal estimation using deep learning for robust surface reconstruction,” in *Proceedings of the International Conference on 3D Vision (3DV)*, pp. 1–10, Dec. 2021.
- [14] M. Kada, “3D reconstruction of simple buildings from point clouds using neural networks with continuous convolutions (ConvPoint),” *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. XLVIII-4/W4-2022, pp. 61–68, Oct. 2022.