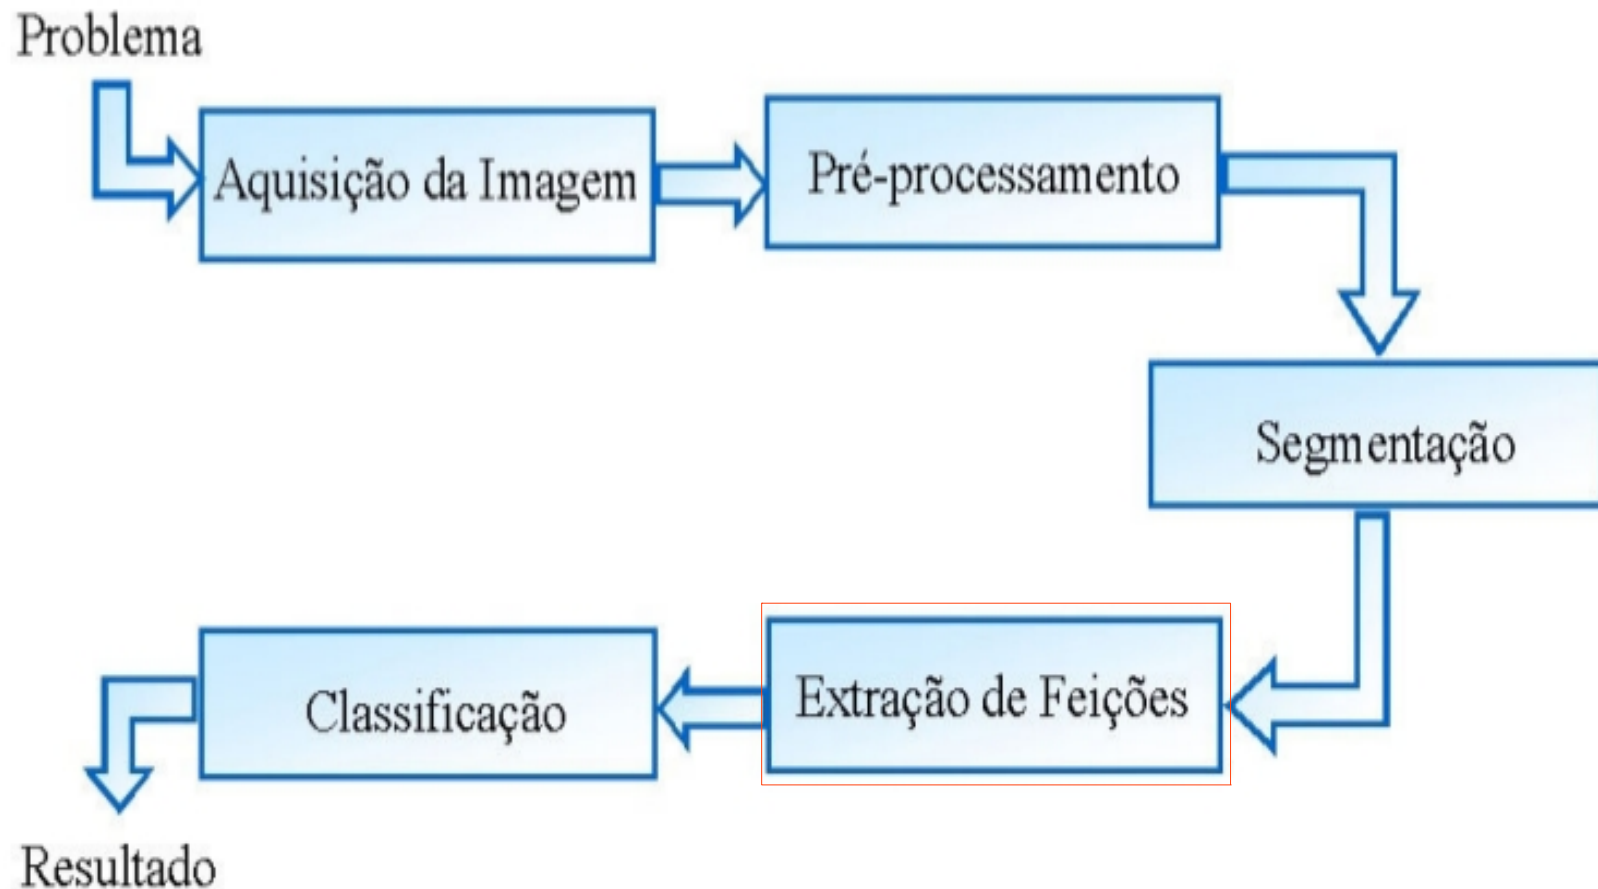


Representação e Descrição



Representação e Descrição

Extração de Feições

Nesta etapa busca-se alguma informação quantitativa de interesse ou que seja básica para a discriminação entre classes de objetos

(GONZALEZ; WOODS, 2000).


Para isso, é necessário escolher a forma de representação/descrição dos dados, que pode ser por Fronteiras (externa) ou por regiões completas (interna).

Erpen, L.R.


Representação e Descrição

Representação de imagens:

1. descrição de contorno



2. descrição de região



Representação e Descrição

Representação de imagens:

1. descrição de contorno;
2. descrição de região.

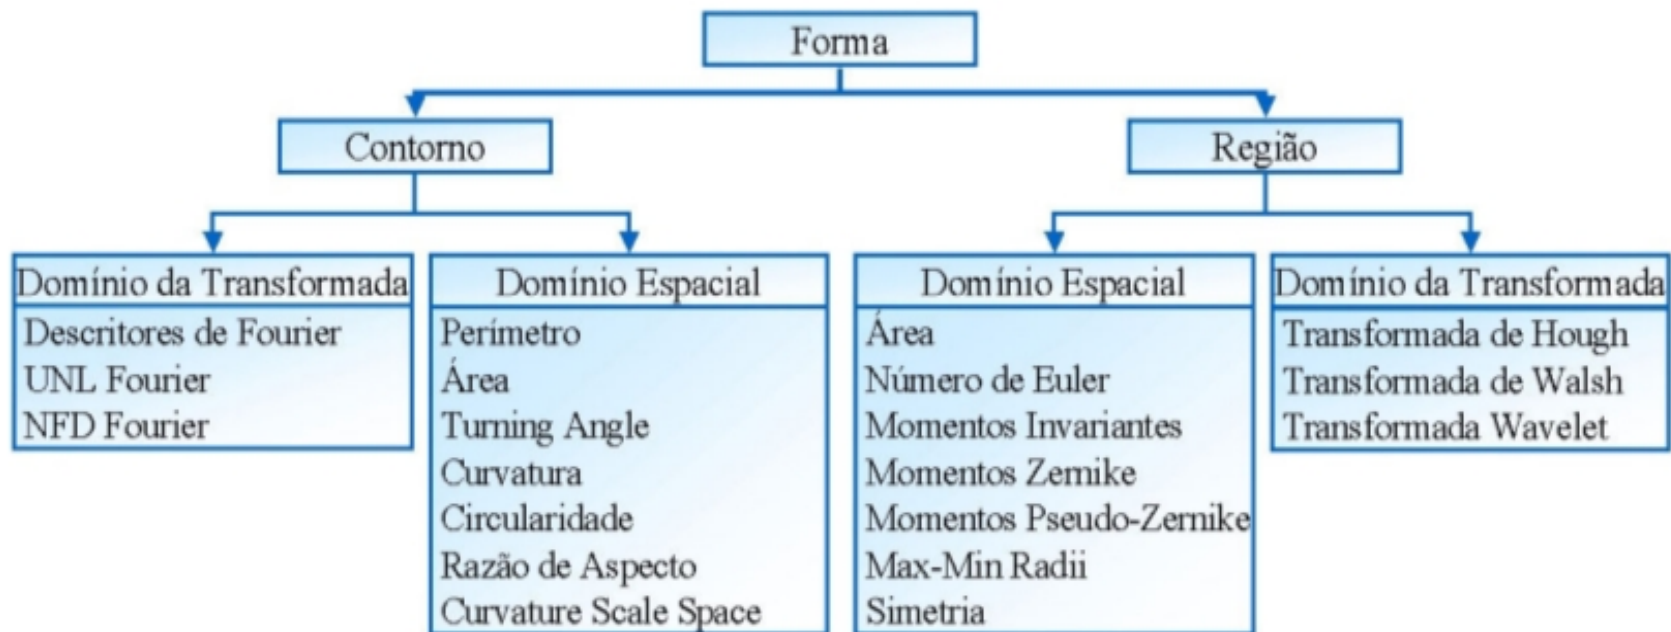


Figura 2.3: Alguns descritores de forma

Representação e Descrição

Descrição de contorno




Figura 2.5: Um objeto visual 2D e seu respectivo contorno

Representação e Descrição

Descrição de contorno - Exemplo

Uma maneira de descrever arestas (pré-segmentadas) é utilizar um código que determina a orientação do rastreio das :





Figura 11.3 Números de direção para (a) código da cadeia de quatro direções; e (b) código da cadeia de oito direções.

Representação e Descrição

Descrição de contorno - Exemplo

Código da cadeia:



- (a) Fronteira digital com a grade de reamostragem sobreposta.
(b) Resultado da reamostragem.
(c) Fronteira codificada utilizando código da cadeia de oito direções.




Figura 11.3 Números de direção para (a) código da cadeia de quatro direções; e (b) código da cadeia de oito direções.

Representação e Descrição

Descrição de contorno - Exemplo

Assinaturas: representação 1D de uma fronteira.
Gráfico da distância entre a fronteira o centroide da forma em função do ângulo:

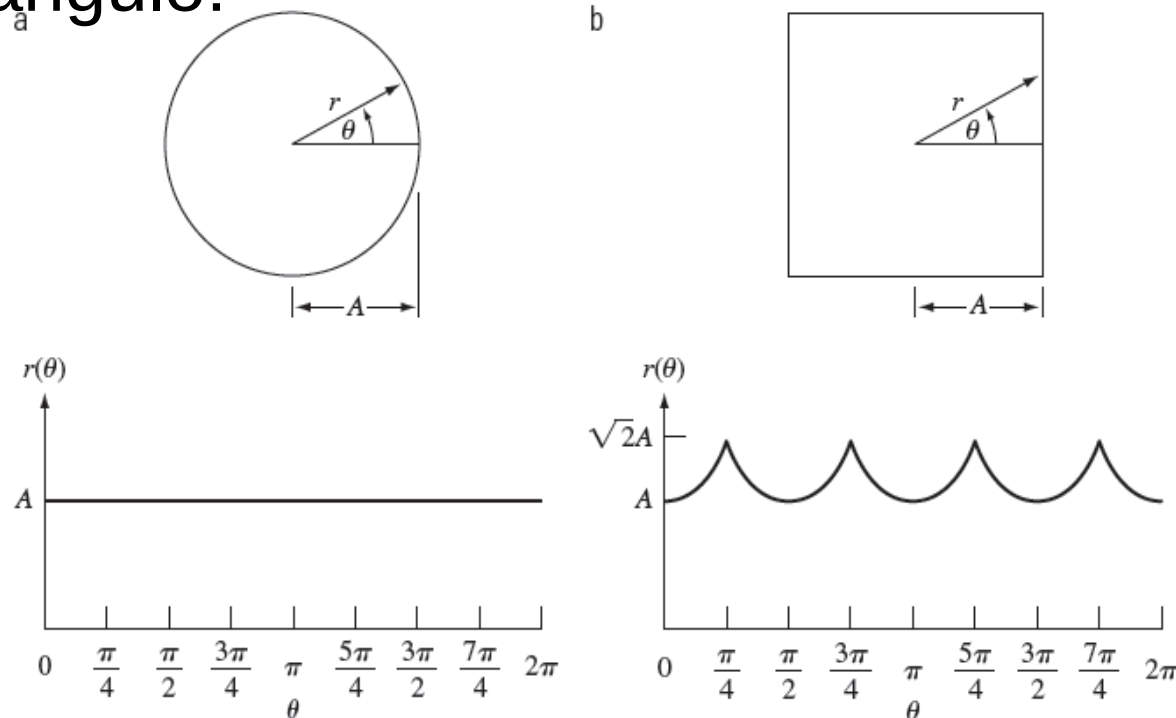


Figura 11.10 Assinaturas de distância em função do ângulo. Em (a), $r(\theta)$ é constante. Em (b), a assinatura consiste de repetições do padrão $r(\theta) = A \sec \theta$ para $0 \leq \theta \leq \pi/4$ e $r(\theta) = A \operatorname{cosec} \theta$ para $\pi/4 < \theta \leq \pi/2$.

Representação e Descrição

Descrição de região:

Duas categorias

- 1- descritores da forma geométrica do objeto;
- 2- descritores da superfície do objeto

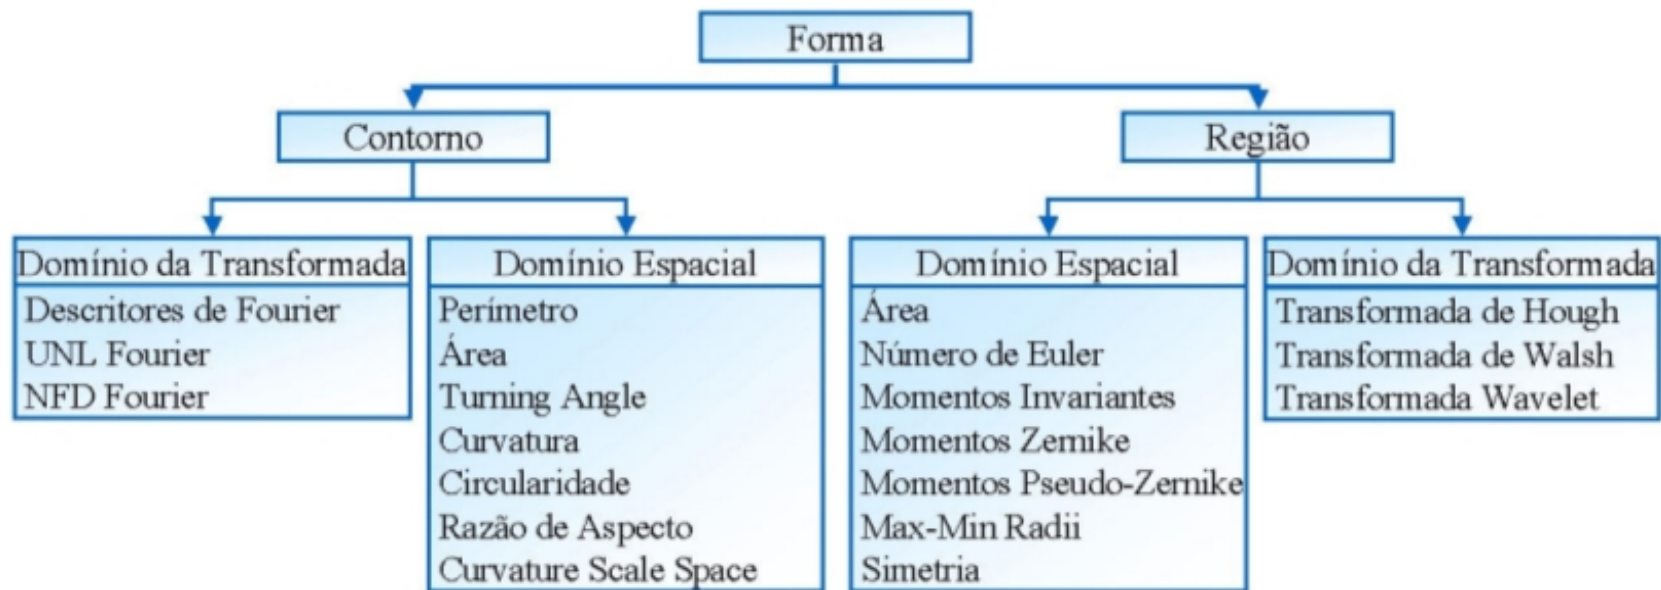


Figura 2.3: Alguns descritores de forma

Representação e Descrição

Descrição de região – Exemplo

Descritores da forma geométrica do objeto:

Área: total de pixels do objeto

Centróide: (X_c, Y_c) do objeto

Perímetro (P) da região

Aspecto: W_{\max}/H_{\max}

Retangularidade: $\text{area}/(W*H)$

Circularidade: $(P*P)/\text{area}$ (objetos complexos grande perimetros)

Representação e Descrição

Descrição de região:

Descritores da textura:

Tabela 11.2 Medidas de textura para as subimagens mostradas na Figura 11.28.

Textura	Média	Desvio padrão	R (normalizado)	Terceiro momento	Uniformidade	Entropia
Suave	82,64	11,79	0,002	-0,105	0,026	5,434
Rugosa	143,56	74,63	0,079	-0,151	0,005	7,783
Regular	99,72	33,73	0,017	0,750	0,013	6,674




Figura 11.28 Os quadrados brancos marcam, da esquerda para a direita, texturas suaves, rugosas e regulares. Estas imagens são de um microscópio ótico de um supercondutor, do colesterol humano e de um microprocessador. (Imagem original: cortesia do dr. Michael W. Davidson, Universidade Estadual da Flórida.)

Representação e Descrição

Descrição de região

Descritores de textura: ocorrências de configurações repetidas de alguns tons de cinza na imagem




Figura 11.29 Como gerar uma matriz de co-ocorrência.

A matriz de coocorrências é a base de um descritor bastante utilizado, conhecido como Local Binary Pattern (LBP)

Representação e Descrição

Descrição de região

Descritores da textura: ocorrências de configurações repetidas de alguns tons de cinza na imagem

Tabela 11.4 Descritores avaliados usando as matrizes de co-ocorrência indicadas na Figura 11.31.

Matriz de co-ocorrência normalizada	Descritor					
	Probabilidade máxima	Correlação	Contraste	Uniformidade	Homogeneidade	Entropia
\mathbf{G}_1/n_1	0,00006	-0,0005	10.838	0,00002	0,0366	15,75
\mathbf{G}_2/n_2	0,01500	0,9650	570	0,01230	0,0824	6,43
\mathbf{G}_3/n_3	0,06860	0,8798	1.356	0,00480	0,2048	13,58




Figura 11.31 Matrizes de co-ocorrência 256×256 , \mathbf{G}_1 , \mathbf{G}_2 e \mathbf{G}_3 , correspondendo da esquerda para a direita às imagens na Figura 11.30.

Representação e Descrição

Descrição de região

HoG Histograma de gradiente orientado

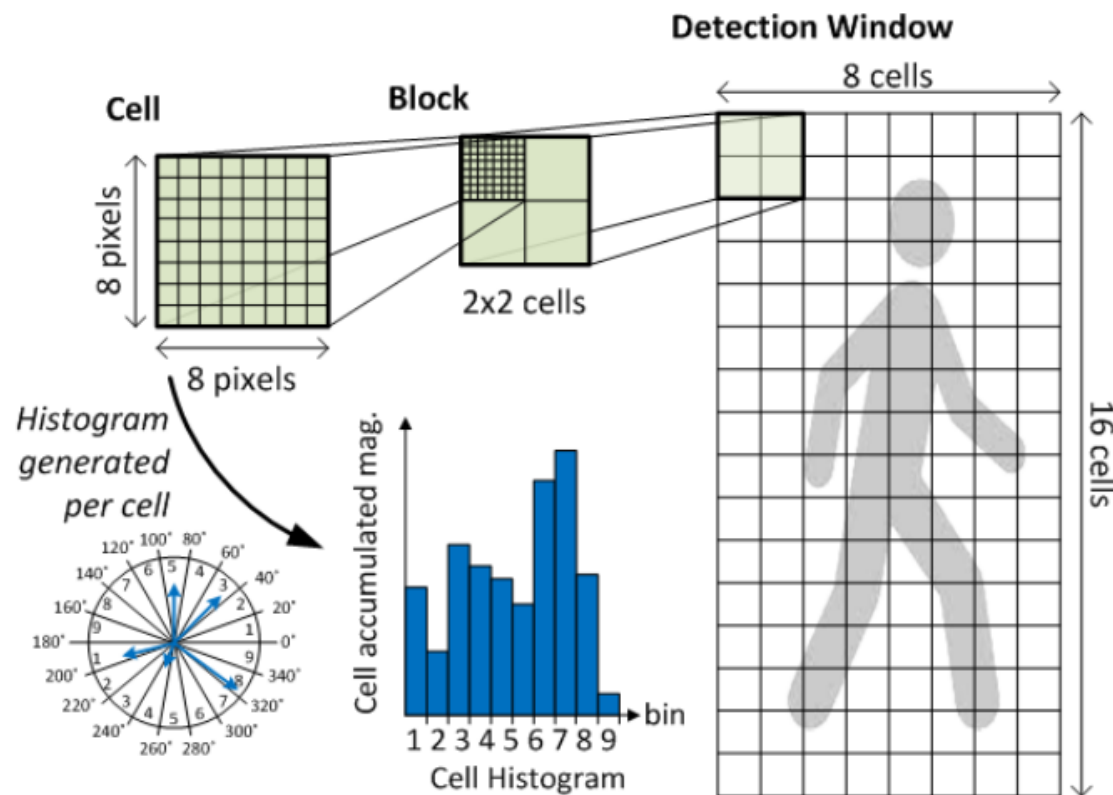


Fig. 2: Detection window divided into blocks and cells producing an array of histograms per window

Representação e Descrição

HoG Histograma de gradiente orientado




Figure 1. An overview of our feature extraction and object detection chain. The detector window is tiled with a grid of overlapping blocks in which Histogram of Oriented Gradient feature vectors are extracted. The combined vectors are fed to a linear SVM for object/non-object classification. The detection window is scanned across the image at all positions and scales, and conventional non-maximum suppression is run on the output pyramid to detect object instances, but this paper concentrates on the feature extraction process.

SVM, mas poderia ser uma Rede Neural ou outro ML

Representação e Descrição

Rede Neural




Figure 1: An artificial neural network [1]





Figure 3: Illustration of a biological neuron (left) and its mathematical model (right) [2].

Representação e Descrição

Ao utilizar descritores, o usual é treinar um modelo Machine Learning (método pelo qual o modelo é treinado a partir de bases de dados contendo casos bem documentados).

Existe sempre a possibilidade de usar uma rede convolucional (CNN), a qual dispensa a extração de features (descritores) previamente determinados.

De certa forma, a própria CNN provê os filtros extratores.

Representação e Descrição

CNN: estado da arte na classificação de imagens

In a CNN, convolution layers play the role of feature extractor. But they are not hand designed. Convolution filter kernel weights are decided on as part of the training process. Convolutional layers are able to extract the local features because they restrict the receptive fields of the hidden layers to be local.

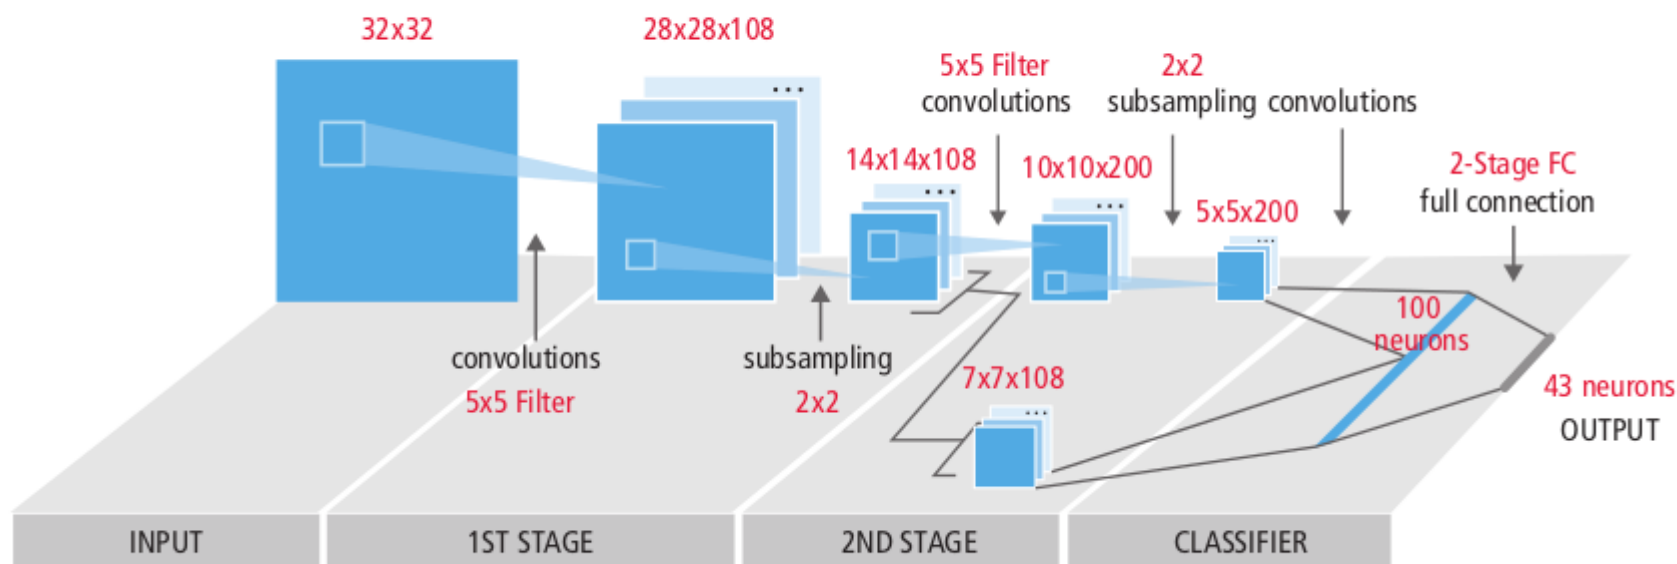


Figure 4: Typical block diagram of a CNN [4]