



COGNEX



COMEÇANDO UM PROJETO DE AUTOMAÇÃO DE FÁBRICA COM DEEP LEARNING

COMEÇANDO UM PROJETO DE AUTOMAÇÃO DE FÁBRICA COM DEEP LEARNING

A análise de imagens com deep learning está abrindo oportunidades de automação de fábricas em uma ampla gama de setores. Da inspeção de defeitos superficiais à classificação de peças variáveis, verificação de montagens finais, classificação da qualidade do produto ou leitura de textos desafiadores, os sistemas de visão habilitados por deep learning podem lidar com inúmeras novas aplicações.

Os sistemas de visão tradicionais ou “baseados em regras” funcionam de forma confiável com peças consistentes e bem fabricadas e se destacam em aplicações de alta precisão. Isso inclui orientação, identificação, medição e inspeção, todas as quais podem ser executadas em velocidades extremamente rápidas e com grande precisão. Este tipo de sistema de visão é ótimo com variáveis: uma peça está presente ou ausente? Exatamente a que distância está este objeto daquele? Onde este robô precisa escolher esta peça? Essas tarefas são fáceis de implementar na linha de montagem em um ambiente controlado. Mas o que acontece quando as coisas não são tão claras?

Entra o deep learning para sistemas de visão. O deep learning usa treinamento baseado em exemplos e redes neurais para analisar defeitos, localizar e classificar objetos e ler marcações impressas. Ao ensinar a uma rede o que é uma boa imagem com base em um conjunto de exemplos rotulados, ele será capaz de dizer a diferença entre uma peça boa e uma defeituosa, considerando as variações esperadas.



No entanto, os gerentes de fábrica hesitam, com razão, em arriscar seus processos em favor das potenciais recompensas de uma nova tecnologia. Se um gerente de planta traz tecnologias novas e que melhoram a eficiência, isso beneficia a empresa. Se trazer uma tecnologia nova e ela ocasionar pioras na linha, os impactos negativos são numerosos.


Mas implementar o deep learning com sucesso em uma estratégia de automação pode gerar economia de custos, melhorias para processos ineficientes, automatizar aplicações de inspeção complexas que são impossíveis com ferramentas de visão baseadas em regras e ajudar a aumentar o rendimento.

As seguintes considerações podem ajudar fábricas e fabricantes que são novos com deep learning a evitar erros dispendiosos e perda de tempo, enquanto geram adesão organizacional para a vantagem considerável da tecnologia. Se feito corretamente, o primeiro projeto de sucesso pode levar a uma implementação mais ambiciosa e estratégica.

Aqui estão cinco áreas a serem consideradas antes de implementar seu projeto piloto de deep learning.

- 1 Defina expectativas adequadas**
- 2 Entenda seu retorno sobre o investimento**
- 3 Planeje recursos e necessidades**
- 4 Comece pequeno com um projeto piloto**
- 5 Passe por uma abordagem de projeto em fases**

Implementar o deep learning com sucesso
em uma estratégia de automação pode gerar economia de custos,
melhorias para processos ineficientes, automatizar aplicações
de inspeção complexas que são impossíveis com ferramentas de
visão baseadas em regras e ajudar a aumentar o rendimento.



1

DEFINA EXPECTATIVAS ADEQUADAS




O deep learning aproveita as redes neurais para treinar uma aplicação de uma biblioteca de imagens, para identificar, por exemplo, o que é uma peça boa e uma ruim. Os projetos de deep learning podem combinar os benefícios do julgamento humano com a escala e dependência de uma aplicação de sistema de visão.

Como acontece com qualquer nova tecnologia, no entanto, existem considerações e compensações que vêm com ela. Embora os sistemas de visão com deep learning prometam resolver muitas aplicações de fábrica complexas, eles não são, de forma alguma, uma panacéia ou solução mágica.


É por isso que definir expectativas adequadas sobre o que o deep learning pode fazer é importante para qualquer projeto; saber antecipadamente algumas das compensações é fundamental.



Uma aplicação de deep learning bem treinada requer um conjunto abrangente de imagens de treinamento que representam uma gama de defeitos e/ou variações de peças aceitáveis para um bom desempenho na produção. Essas imagens também precisam ser adquiridas sob condições de iluminação de fabricação e apresentação de peças. Isso é essencial para que qualquer projeto de deep learning seja bem-sucedido.



Além disso, uma vez que as imagens tenham sido coletadas, elas precisarão ser devidamente classificadas e rotuladas. Em outras palavras, um especialista em qualidade precisa estar envolvido em qualquer projeto desde o início.



Neste exemplo, a classificação se refere à decisão geral “boa/ruim” para cada peça, enquanto “Rotulagem” é a marcação de pixels com defeitos específicos na imagem.

Finalmente, uma vez que o desenvolvimento do sistema tenha sido concluído, ele precisará ser testado antes de entrar em produção.

Às vezes, os sistemas de deep learning têm um bom desempenho no laboratório, mas têm dificuldades quando implementados no ambiente de produção. Muitas vezes, a frustração do usuário decorre das diferenças subestimadas entre as soluções de deep learning e os sistemas de visão mais familiares baseados em regras.

Qualificar uma solução de visão com deep learning é um processo iterativo que requer que o sistema seja instalado em uma linha de produção. E, ao contrário dos sistemas de visão tradicionais, treinamento e validação das imagens para deep learning devem ser feitos durante a fase de desenvolvimento — não podem esperar até o teste de aceitação de fábrica. O deep learning requer um grande número de amostras para treinar, o que pode exigir tempo para capturar o conjunto representativo de imagens necessárias para treinar uma ferramenta de deep learning com bom desempenho.



2

ENTENDA SEU RETORNO SOBRE O INVESTIMENTO

O que o deep learning vai fazer por mim? Isso é provavelmente a pergunta mais pertinente que qualquer empresa ou gerente de fábrica poderia fazer. O que essa pergunta realmente significa é qual será o retorno do investimento. Os sistemas deep learning não são baratos, portanto, deve haver um benefício tangível para realizar tal esforço.

Um retorno realista do projeto é normalmente alcançado reduzindo custos enquanto mantém rendimentos semelhantes aos da abordagem atual ou melhora significativamente os rendimentos, mantendo os mesmos custos. O rendimento também é um fator no ROI, especialmente quando comparado aos processos manuais.

Outra maneira de pensar sobre o ROI é de uma perspectiva direta e indireta.

O **ROI direto** é simples, pois você está apenas comparando o custo da solução deep learning com a abordagem atual. Isso inclui tudo, desde custos de software e hardware até tempo e custos de desenvolvimento, bem como custos de coleta de imagens, custos de mão de obra e treinamento, por exemplo.

O **ROI indireto** mede todos os benefícios adicionais além do valor investido. Mesmo se um gerente de projeto não puder atribuir um valor monetário preciso que os benefícios indiretos produzem, é importante os considerar. Rastreabilidade, melhoria contínua, controle de processo upstream e análises são necessárias para a automação de fábrica e transformação digital em curso.




3

PLANEJE RECURSOS E NECESSIDADES

Em qualquer projeto de deep learning existem quatro tarefas principais a serem realizadas. É possível que um funcionário cubra mais de uma função, mas é útil estar ciente dos tipos de especialistas necessários desde o início. Por exemplo, embora a tecnologia deep learning seja baseada em redes neurais, em uma configuração de automação de fábrica, um especialista em rede neural não é realmente necessário. Em vez disso, um especialista em sistemas de visão com um conhecimento básico dos princípios do deep learning seria suficiente.

Aqui estão os conjuntos de habilidades necessárias para uma implementação de deep learning:



Desenvolvedor de Visão


O desenvolvedor implementa solução de análise de visão com deep learning, bem como otimiza a iluminação e formação de imagem.



Especialista em Qualidade

O especialista em qualidade analisa as imagens e as classifica, que é o ato de determinar a verdade fundamental para a peça: aprovado/reprovado, tipo de defeito, etc. A importância da classificação de imagens não pode ser


subestimada porque a abordagem de aprendizagem baseada em exemplos do deep learning depende de clareza e imagens consistentemente classificadas para treinar o sistema.



Rotulador de Imagens

Rotular imagens é o processo interativo de indicar quais regiões na imagem definem o defeito ou características de interesse. A rotulagem é um processo preciso e orientado para os detalhes que precisa ser feito de forma concisa

e consistente em todas as imagens do conjunto de treinamento. Conforme o projeto acumula conjuntos de imagens maiores, pode ser necessário um funcionário separado do especialista em qualidade para preencher essa função.



Coletor de Dados

O coletor de dados precisa registrar e organizar todas as informações, incluindo imagens, notas, rótulos e metadados. Otimizar um sistema deep learning envolve testá-lo em relação a esses conjuntos de dados. Um coletor de dados

também pode registrar as decisões dos inspetores se um procedimento manual estiver sendo usado para associá-los a determinados conjuntos de imagens.

Também é importante notar — além dessas funções — que qualquer iniciativa de deep learning exigirá um PC poderoso baseado em Windows com uma unidade de processamento gráfico (GPU) instalada.

4

COMECE PEQUENO COM UM PROJETO PILOTO

Na empolgação de aplicar novas tecnologias, pode ser tentador começar a jornada com o desafio mais difícil e ambicioso da lista. Se o deep learning pode resolver isso, muitos gerentes de automação podem pensar que ele pode resolver qualquer coisa. Isso, no entanto, só levará as empresas a um caminho de frustração e atrasos por motivos que não tem nada a ver com a tecnologia deep learning.

Os desafios mais ambiciosos podem ser inerentemente muito complexos ou instáveis; o projeto pode ser cancelado se não mostrar progresso rápido e ROI; ou, pior ainda, mesmo que seja um sucesso, pode levar as empresas a conclusões erradas.




Em vez disso, é importante começar pequeno. Escolha um projeto com um retorno claro que não pode ser facilmente resolvido com a visão tradicional baseada em regras, mas que não seja tão difícil a ponto de nunca chegar à produção. Concentre-se em uma necessidade central e desenvolva uma competência central e a compreensão do que o deep learning pode e não pode fazer em um ambiente de automação de fábrica.

Projetos piloto de deep learning devem ter dois objetivos principais: avaliar sua utilidade mais ampla para uma estratégia de automação mais holística e automatizar um processo de inspeção ou verificação que não é feito manualmente ou não pode ser feito de jeito algum.

Então, o que torna um bom primeiro projeto a ser abordado? Isso é único para cada empresa, certamente. No entanto, na maioria das configurações de fabricação, os dois melhores para começar são normalmente no final da linha para a inspeção final ou verificação de montagem em linha para detectar problemas entre as etapas de fabricação. Essas duas aplicações são boas para um projeto piloto porque as aplicações tradicionais de visão lutam com a gama de defeitos potenciais para identificar, bem como com as variações na iluminação, perspectiva e aparência da peça. O deep learning é exclusivamente qualificado para resolver essas variações. Normalmente, esses tipos de inspeções também têm critérios de inspeção bem definidos já estabelecidos; eliminando assim a necessidade de criar e solidificar as métricas de qualidade antes de implementar uma solução automatizada.

5

PASSE POR UMA ABORDAGEM DE PROJETO EM FASES



Os projetos de deep learning devem ser abordados em quatro fases. As diferentes fases do projeto são:

1. Prototipagem



- Compreenda o processo atual e determine se o deep learning é um bom candidato para resolvê-lo
- Adquira um pequeno banco de dados de imagens classificadas e rotuladas
- Construa um sistema de prova de conceito para testar a abordagem

2. Coleta de Dados de Imagem




- Integre a câmera e o sistema de iluminação na linha de produção
- Comece a coletar e organizar dados de imagem e resultados de inspeção manual
- Estabeleça dados de linha de base
- Otimize e rotule conjuntos de imagens de forma consistente

3. Otimização



- Esta será a etapa mais longa: melhore a solução deep learning até que atenda às metas de desempenho
- Compare os resultados do deep learning com os resultados iniciais e manuais
- Ajuste o sistema e retreine conforme necessário

4. Validação e Implementação



- Qualifique a solução e comece a usá-la na produção
- Passe nos testes de aceitação de fábrica e configuração de bloqueio
- Integre na produção e expanda para linhas adicionais
- Prepare-se para mudanças futuras e estabeleça monitoramento contínuo e processo de melhorias

ALCANÇANDO O SUCESSO COM DEEP LEARNING

Ao conduzir pequenos projetos gerenciáveis em uma abordagem sensata em fases, as equipes de automação podem preparar suas empresas para o sucesso a longo prazo com a análise de imagem por deep learning. Enquanto a experiência dos sistemas de visão tradicionais baseados em regras fornece uma base sólida para o deep learning, as duas tecnologias são diferentes o suficiente em seu escopo, execução, requisitos e casos de uso.

Mas, começando com expectativas realistas, criando experiência e aprendendo quais aplicações são mais bem resolvidas com deep learning, as empresas de manufatura começarão a entender o poder que o deep learning adiciona às estratégias de automação de fábrica.

Para saber mais sobre as soluções de deep learning da Cognex, visite

www.cognex.com/pt-br/products/deep-learning





www.cognex.com

Empresas em todo o mundo confiam na visão e leitura de código de barras da Cognex para otimizar a qualidade do produto, reduzir custos e controlar a rastreabilidade.

Sede Corporativa One Vision Drive Natick, MA 01760 EUA

Escritórios de Vendas Regionais

Américas

América do Norte	+1 844-999-2469
Brasil	+55 11 4210 3919
México	+800 733 4116

Europa

Austria	+49 721 958 8052
Bélgica	+32 289 370 75
França	+33 1 7654 9318
Alemanha	+49 721 958 8052

Hungria	+36 800 80291
Irlanda	+44 121 29 65 163
Itália	+39 02 3057 8196
Holanda	+31 207 941 398
Polónia	+48 717 121 086
Espanha	+34 93 299 28 14
Suécia	+46 21 14 55 88
Suiça	+41 445 788 877
Turquia	+90 216 900 1696
Reino Unido	+44 121 29 65 163

Ásia

China	+86 21 6208 1133
Índia	+9120 4014 7840
Japão	+81 3 5977 5400
Coreia	+82 2 530 9047
Malásia	+6019 916 5532
Cingapura	+65 632 55 700
Taiwan	+886 3 578 0060
Tailândia	+66 88 7978924
Vietnã	+84 2444 583358

© Copyright 2020, Cognex Corporation. Todas as informações neste documento estão sujeitas à alterações sem aviso prévio. Todos os direitos reservados. Cognex é uma marca registrada da Cognex Corporation. Todas as outras marcas registradas são propriedade de seus respectivos proprietários. Lit. No. EBDLDG-PTBR-12-2020